

Министерство науки и высшего образования Российской Федерации
Федеральное государственное автономное образовательное учреждение
высшего образования
«КАЗАНСКИЙ (ПРИВОЛЖСКИЙ) ФЕДЕРАЛЬНЫЙ УНИВЕРСИТЕТ»
Институт Вычислительной математики и информационных технологий

Отчет
учебной практики (научно-исследовательская работа (получение первичных
навыков научно-исследовательской работы))

Обучающийся Миронов Егор Петрович гр.09-535 _____
(ФИО студента) (Группа) (Подпись)

Научный руководитель:
канд. техн. наук, доцент КСАИТ Николаев К.С. _____
(Подпись)

Руководитель практики от КФУ:

Доцент кафедры САИТ Андрианова А.А.

Оценка за практику _____
(Подпись)

Дата сдачи отчета « ____ » _____ 2026 г.

Казань – 2026

СОДЕРЖАНИЕ

ВВЕДЕНИЕ	3
1. Анализ предметной области и постановка задачи.....	4
2. Анализ существующих подходов и технологий	7
2.1. OCR-технологии	9
2.2. Подходы к классификации данных.....	11
2.3. Методы предобработки изображений	14
3. Прототип конвейера.....	15
4. Экспериментальное исследование	19
4.1. Эксперимент 1 – сравнение OCR	20
4.2. Эксперимент 2 – влияние предобработки	22
4.3. Эксперимент 3 – сравнение классификации	23
4.4. Итоговые результаты экспериментов	25
5. Перспективы развития.....	29
ЗАКЛЮЧЕНИЕ	30
СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ.....	32
ПРИЛОЖЕНИЯ	35
Приложение 1. Статья.....	35
Приложение 2. Программный код	38

ВВЕДЕНИЕ

Учебная практика (научно-исследовательская работа (получение первичных навыков научно-исследовательской работы)) проходила на кафедре системного анализа и информационных технологий Института вычислительной математики и информационных технологий КФУ с 09 февраля 2026 по 06 июня 2026 года.

Целью практики является исследование современных подходов к автоматизации обработки финансовых документов, а также разработка и экспериментальное исследование прототипа системы распознавания и классификации транзакций на основе анализа изображений.

В рамках практики рассматривалась реализация конвейер обработки данных на основе OCR, включающего этапы предобработки изображений, распознавания текста, структуризации полученных данных и последующей классификации транзакций. Исследование проводилось с целью анализа влияния различных компонентов системы на итоговое качество классификации, а также определения наиболее эффективных подходов к организации подобного конвейера.

За время работы в семестре были изучены современные OCR-решения и методы классификации данных, реализован базовый прототип системы, подготовлен экспериментальный блок данных и проведен ряд экспериментов.

1. Анализ предметной области и постановка задачи

В условиях активной цифровизации финансовой сферы объем документов, подлежащих обработке, продолжает стремительно возрастать. Банковские выписки, чеки, квитанции, платежные поручения и иные финансовые документы ежедневно формируются в больших количествах, поступая как в электронном виде, так и в аналоговом. При этом существенная часть подобных данных остается неструктурированной, что значительно осложняет их автоматическую обработку и последующий анализ [1].

Традиционные подходы требуют значительных временных затрат и сопровождаются высокой вероятностью возникновения ошибок, обусловленных человеческим фактором. Особенно заметно данная проблема проявляется при работе с большими объемами документов, различающихся по формату, качеству изображения и структуре представления информации. Дополнительную сложность представляет качество исходных изображений. Документы могут содержать шумы, артефакты сжатия, неравномерное освещение и другие дефекты. Подобные факторы оказывают существенное влияние на работу OCR-систем, снижая точность распознавания текста и, как следствие, ухудшая качество последующей классификации данных.

Существующие системы автоматизации обработки документов в большинстве случаев ориентированы либо на строго определенные шаблоны документов, либо требуют значительных объемов размеченных данных для обучения моделей машинного обучения. При изменении структуры документа или появлении новых форматов эффективность подобных решений может существенно снижаться, что делает актуальным исследование более гибких и модульных подходов к построению систем анализа финансовых документов.

Одним из наиболее перспективных направлений в данной области является применение конвейера обработки данных на основе OCR, в рамках которого процесс обработки разделяется на несколько независимых этапов: предварительную обработку изображения, распознавание текста, структуризацию данных и классификацию транзакций. Подобный подход

позволяет независимо исследовать и совершенствовать отдельные компоненты системы, а также проводить сравнительный анализ различных технологий и методов на каждом этапе обработки.

Следует отметить, что задача классификации финансовых транзакций по изображениям документов относится к числу комплексных задач. В отличие от классических задач классификации текстовых данных, в рассматриваемом случае исходная информация первоначально представлена в виде изображений, содержащих как полезные данные, так и различные визуальные искажения, возникающие в процессе получения документа. Также одной из ключевых особенностей подобных задач является высокая вариативность входных данных. Финансовые документы могут существенно отличаться по структуре, расположению элементов, формату представления текста и качеству изображения. Даже документы одного типа, сформированные различными организациями или полученные из разных источников, зачастую имеют различные шаблоны, размеры шрифтов, оформление и структуру размещения информации. Подобная неоднородность существенно усложняет построение универсальных алгоритмов обработки.

Особую сложность представляет неструктурированность получаемой информации. После этапа OCR система, как правило, получает набор текстовых фрагментов, не содержащих явных связей между сущностями документа. Для дальнейшей обработки возникает необходимость выделения значимых элементов, нормализации текста, устранения ошибок распознавания и преобразования данных в формат, пригодный для последующей классификации. Данный этап требует реализации механизмов структуризации, позволяющих формировать более устойчивое и информативное представление документа.

Еще одной особенностью задачи является наличие различных подходов к классификации транзакций. Правило-ориентированные методы, основывающиеся на заранее заданных правилах и шаблонах, обеспечивают высокую интерпретируемость результатов и позволяют эффективно

обрабатывать типовые случаи. Однако при увеличении числа форматов документов и усложнении структуры данных подобные решения становятся трудно масштабируемыми. Методы машинного обучения, напротив, обладают большей гибкостью и способны выявлять сложные зависимости в данных, однако требуют подготовки размеченных наборов данных и чувствительны к качеству обучающей выборки.

Актуальность рассматриваемой задачи обусловлена не только практической востребованностью автоматизации обработки финансовых документов, но и необходимостью исследования влияния отдельных компонентов конвейера на итоговое качество классификации. Особый интерес представляет анализ зависимости качества классификации от используемого OCR-модуля, методов предобработки и постобработки [2].

2. Анализ существующих подходов и технологий

В настоящее время задачи автоматизированной обработки документов реализуются преимущественно с использованием двух основных подходов: «от начала и до конца» моделей и систем основанных на OCR. Оба направления активно развиваются, однако отличаются как принципами организации обработки данных, так и требованиями к обучению, объему данных и особенностям практического применения [3].

Подход «от начала и до конца» предполагает построение единой модели, осуществляющей обработку изображения документа и последующую классификацию без явного выделения промежуточных этапов. В подобных системах нейросеть получает на вход изображение документа и непосредственно формирует итоговый результат классификации. В основе таких решений используются глубокие нейронные сети, объединяющие методы компьютерного зрения и обработки последовательностей данных.

Основным преимуществом таких моделей является возможность автоматического извлечения признаков из данных без необходимости ручного проектирования промежуточных этапов обработки. Подобные системы способны выявлять сложные зависимости между визуальными особенностями документа и итоговыми классами транзакций, обеспечивая высокую точность при наличии достаточного объема обучающих данных. Кроме того, архитектура таких решений позволяет минимизировать влияние ошибок отдельных компонентов, поскольку модель обучается оптимизировать весь процесс обработки целиком.

Несмотря на преимущества, использование данного решения сопровождается рядом существенных ограничений. Для эффективного обучения подобных моделей требуется большой объем размеченных данных, подготовка которых является трудоемкой задачей. Дополнительно возникает проблема адаптации к новым форматам документов: изменение структуры входных данных зачастую требует повторного обучения модели или переопределения параметров. В практических условиях подобные требования

могут существенно ограничивать возможность использования «от начала и до конца» подходов.

Альтернативным направлением являются OCR-ориентированные системы, в рамках которых процесс обработки документа разделяется на несколько независимых этапов. Подобный процесс включает предварительную обработку изображения, распознавание текста с использованием OCR-технологий, структуризацию полученной информации и последующую классификацию данных. В отличие от автоматических моделей, подобный подход предполагает явное выделение промежуточных этапов обработки, каждый из которых может исследоваться и оптимизироваться независимо.

Одним из ключевых преимуществ OCR-ориентированного подхода является модульность архитектуры. Использование независимых компонентов позволяет заменять отдельные модули системы без необходимости полного пересмотра всей архитектуры. Например, OCR-движок может быть заменен на более эффективное решение без изменения логики классификации, а модуль предобработки может адаптироваться под особенности конкретного типа документов.

Дополнительным преимуществом OCR-ориентированного конвейера является более высокая интерпретируемость результатов. Поскольку каждый этап обработки выполняет ограниченный набор задач, становится возможным анализ возникающих ошибок и определение компонентов, оказывающих наибольшее влияние на итоговое качество классификации. Подобная особенность особенно важна в исследовательских задачах, где требуется не только получение итогового результата, но и анализ поведения системы на различных этапах обработки.

Следует отметить, что такой подход также обладает рядом ограничений. Качество работы системы во многом определяется эффективностью OCR-модуля, поскольку ошибки распознавания текста оказывают накопительный эффект и влияют на все последующие этапы обработки. При низком качестве изображений или наличии значительных визуальных искажений точность OCR

может существенно снижаться, что негативно отражается на качестве классификации транзакций.

Сравнивая рассматриваемые подходы, можно отметить, что «от начала и до конца» модели демонстрируют высокую эффективность при наличии крупных размеченных данных и стабильных форматов документов, тогда как OCR-ориентированные системы обладают большей гибкостью и удобством для экспериментальных исследований. Учитывая исследовательский характер данной работы, а также необходимость проведения сравнительного анализа отдельных компонентов системы, в качестве основного направления был выбран OCR-ориентированный подход, позволяющий независимо исследовать каждый из модулей на итоговое качество работы конвейера.

2.1. OCR-технологии

Одним из ключевых этапов обработки документов в рамках OCR-ориентированного конвейера является распознавание текстовой информации, содержащейся на изображениях. Эффективность работы OCR-модуля напрямую влияет на качество последующей структуризации и классификации данных, поскольку ошибки, возникающие при распознавании текста, способны накапливаться на следующих этапах обработки. В связи с этим выбор OCR-технологии представляет собой одну из наиболее значимых задач при проектировании систем автоматизации обработки документов.

Под OCR (Optical Character Recognition) понимается совокупность методов и алгоритмов, предназначенных для преобразования текстовой информации, представленной в виде изображения, в машиночитаемый формат. Современные OCR-системы способны работать как с печатным, так и с рукописным текстом, обрабатывая изображения различного качества и структуры. Однако эффективность распознавания во многом зависит от особенностей документа, качества изображения и используемых алгоритмов обработки.

Исторически развитие OCR-технологий проходило через несколько этапов, отличающихся используемыми методами анализа символов и

принципами распознавания текста. Одними из первых стали шаблонные методы, основанные на сравнении изображения символа с заранее подготовленными эталонами. Подобные подходы демонстрировали приемлемую точность при работе с ограниченным набором шрифтов и качественными изображениями, однако оказывались малоэффективными при наличии искажений или вариативности представления символов.

Дальнейшее развитие OCR-систем привело к появлению признаковых методов, в рамках которых распознавание основывалось на анализе отдельных характеристик символов, включая линии, углы, замкнутые области и иные геометрические признаки. Использование подобных подходов позволило повысить устойчивость систем к изменениям шрифта и незначительным визуальным искажениям, однако эффективность распознавания по-прежнему оставалась ограниченной при работе со сложными изображениями.

Следующим этапом развития стали структурные методы, анализирующие внутреннее строение символов и взаимосвязи между их элементами. Подобные алгоритмы обеспечивали более высокую гибкость обработки и легли в основу многих OCR-систем предыдущих поколений. Тем не менее современные задачи обработки документов, характеризующиеся высокой вариативностью данных и наличием сложных визуальных дефектов, потребовали использования более устойчивых подходов [4].

Наиболее активно в настоящее время развиваются нейросетевые OCR-технологии, использующие методы глубокого обучения для распознавания текста. Подобные системы строятся на основе сверточных и рекуррентных нейронных сетей, обеспечивающих автоматическое извлечение признаков из изображений и адаптацию к различным типам документов. Использование нейросетевых архитектур позволило существенно повысить качество распознавания текста на изображениях низкого качества, содержащих шумы, искажения и сложный фон [5].

В рамках данной работы исследовались EasyOCR и RapidOCR. Выбор указанных систем был обусловлен их открытостью, доступностью для

интеграции и возможностью проведения сравнительного анализа в рамках единого конвейера.

EasyOCR представляет собой OCR-систему, основанную на использовании нейросетевых архитектур и библиотеки PyTorch. В основе работы решения лежит комбинация сверточных нейронных сетей и рекуррентных моделей, позволяющих выполнять распознавание текста на изображениях различного качества. Одним из преимуществ EasyOCR является поддержка большого количества языков и относительная простота интеграции в исследовательские проекты.

RapidOCR, в свою очередь, ориентирован преимущественно на задачи обработки документов и включает специализированные механизмы анализа текстовых областей. Решение характеризуется более высокой скоростью обработки и устойчивостью к отдельным типам визуальных искажений, что делает его перспективным для задач автоматизации документооборота. Дополнительно данное OCR-решение предоставляет инструменты, ориентированные на работу с пониманием документов, что особенно важно в контексте структуризации финансовых документов.

Следует отметить, что эффективность OCR-систем определяется не только архитектурой используемых моделей, но и качеством предварительной обработки изображений. Методы предобработки, направленные на уменьшение шумов, повышение контрастности и нормализацию изображений, способны существенно влиять на точность распознавания текста. По этой причине OCR-модуль в рамках данной работы рассматривался не изолированно, а как часть общего процесса, взаимодействующая с предобработкой и последующей классификацией данных.

2.2. Подходы к классификации данных

После выполнения этапов распознавания и структуризации текста одной из ключевых задач системы становится классификация транзакций на основе полученных данных. Именно данный этап определяет итоговую интерпретацию документа, позволяя автоматически относить транзакции к определенным

категориям в зависимости от их содержимого. В современных системах обработки документов используются различные подходы к классификации данных, отличающиеся принципами работы, требованиями к данным и степенью адаптивности к новым форматам документов [6].

Одним из наиболее распространенных подходов являются правило-ориентированные системы, основывающиеся на использовании заранее определенных правил и шаблонов обработки данных. В рамках подобных решений классификация выполняется путем анализа ключевых слов, регулярных выражений, структуры текста и иных признаков, формализованных в виде набора логических условий. Например, наличие определенных терминов или шаблонов записи может использоваться для автоматического определения типа транзакции или категории документа.

Основным преимуществом правило-ориентированных подходов является высокая интерпретируемость результатов. Поскольку логика принятия решений задается явно, становится возможным отслеживание причин классификации и оперативная корректировка правил при обнаружении ошибок. Дополнительно подобные системы демонстрируют устойчивость при обработке типовых документов с предсказуемой структурой, не требуя значительных объемов обучающих данных.

Несмотря на перечисленные преимущества, использование таких методов сопровождается рядом ограничений. При увеличении числа поддерживаемых форматов документов и усложнении структуры данных объем правил начинает быстро возрастать, что существенно усложняет сопровождение системы. Кроме того, подобные решения плохо адаптируются к нестандартным случаям и оказываются чувствительными к ошибкам OCR, поскольку даже незначительное изменение текста способно нарушить выполнение заранее определенного правила.

Альтернативным направлением являются методы машинного обучения, предполагающие автоматическое выявление зависимостей в данных на основе обучающих выборок. В отличие от правило-ориентированных систем, модели

машинного обучения не требуют явного описания логики классификации, формируя внутренние представления признаков в процессе обучения на размеченных данных.

Применение ML-подходов позволяет повысить гибкость системы и обеспечить обработку более сложных сценариев, включая неоднозначные или частично поврежденные документы. Модели способны учитывать совокупность признаков и выявлять скрытые закономерности в данных, что особенно важно при работе с неструктурированной информацией, полученной после OCR-распознавания.

Вместе с тем методы машинного обучения предъявляют повышенные требования к качеству обучающих данных. Эффективность классификатора напрямую зависит от объема и разнообразия данных, а наличие OCR-ошибок или несбалансированности классов способно существенно снижать качество модели.

В рамках данной работы исследовались оба подхода к классификации транзакций. Правило-ориентированный модуль использовался для обработки типовых и явно определяемых случаев, в которых возможно формализовать правила классификации на основе ключевых признаков документа. ML-подход, в свою очередь, рассматривался как инструмент обработки более сложных сценариев, требующих выявления скрытых зависимостей между признаками данных.

Следует отметить, что на практике наиболее перспективными зачастую оказываются гибридные системы, сочетающие преимущества правило-ориентированных и ML-подходов. В подобных решениях правила используются для обработки наиболее очевидных случаев и предварительной фильтрации данных, тогда как модели машинного обучения применяются для классификации неоднозначных или сложных документов. Подобная комбинация позволяет одновременно обеспечить интерпретируемость системы и повысить ее устойчивость к вариативности входных данных.

2.3. Методы предобработки изображений

Качество работы OCR-систем во многом определяется состоянием входного изображения, поступающего на этап распознавания текста. Даже современные нейросетевые OCR-модели, обладающие высокой устойчивостью к визуальным искажениям, сохраняют чувствительность к шумам, размытости, низкому разрешению и другим дефектам изображения. В связи с этим важным этапом построения конвейера является предварительная обработка изображений, направленная на повышение качества входных данных и улучшение итоговой точности распознавания текста.

Под предобработкой понимается совокупность методов обработки изображения, применяемых перед этапом OCR. Основной задачей предварительной обработки является уменьшение количества визуальных помех и приведение изображения к более удобному для анализа виду. В зависимости от особенностей документов и используемого OCR-решения предобработка может оказывать как положительное, так и нейтральное влияние на итоговое качество распознавания.

Следует отметить, что эффективность предобработки во многом зависит от используемого OCR-решения. Одни OCR-системы демонстрируют устойчивость к отдельным типам шумов и способны эффективно работать с минимальной обработкой изображений, тогда как другие требуют более тщательной подготовки входных данных. В ряде случаев избыточная обработка изображения способна не улучшать, а ухудшать итоговое качество распознавания, изменяя визуальные особенности символов и нарушая внутренние механизмы работы OCR-модели [7].

В рамках данной работы модуль предобработки рассматривался как один из важных компонентов общего конвейера. Исследование влияния методов предварительной обработки проводилось в контексте их взаимодействия с OCR-модулями и последующей классификацией транзакций. Подобный подход позволил оценить не только изменение качества распознавания текста, но и влияния на итоговую точность всей системы в целом.

3. Прототип конвейера

В рамках данной работы была реализована предварительная система классификации транзакций. При проектировании архитектуры особое внимание уделялось модульности системы, обеспечивающей возможность независимого исследования, замены и сравнительного анализа отдельных компонентов обработки данных. Подобный подход позволяет не только упростить экспериментальное исследование различных технологий, но и обеспечить гибкость дальнейшего развития системы.

В основе реализованного прототипа лежит последовательная обработка изображения документа, включающая этапы предварительной обработки, распознавания текста, структуризации данных и классификации транзакций. На вход системы поступает изображение финансового документа, которое в свою очередь поэтапно проходит каждый модуль конвейера.

На этапе предварительной обработки выполняется подготовка изображения документа к последующему распознаванию текста. Основной задачей данного этапа является повышение качества OCR за счёт уменьшения влияния шумов, неравномерного освещения и особенностей сканирования документов. В качестве основных операций предобработки используется:

- преобразование изображения в оттенки серого,
- бинаризация изображения для выделения текстовых областей,
- подавление шумов с использованием фильтрации,
- нормализация контраста изображения.

Подобная обработка позволяет повысить точность извлечения текста и снизить количество ошибок OCR-модулей.

После завершения предварительной обработки изображение передается далее по конвейеру, где осуществляется извлечение текстовой информации из изображения. Для извлечения текстовой информации был реализован модуль OCR. Архитектура системы предусматривает возможность подключения различных OCR-движков через единый интерфейс, что обеспечивало независимость остальных компонентов конвейера от конкретной реализации

распознавания. В рамках создания прототипа были интегрированы два решения EasyOCR и RapidOCR.

EasyOCR представляет собой библиотеку оптического распознавания текста на основе глубоких нейронных сетей, реализованную на базе фреймворка PyTorch.

Процесс распознавания состоит из двух основных этапов:

- 1) детектирование текстовых областей с посредством CRAFT,
- 2) распознавание текста внутри найденных областей при помощи рекуррентной нейронной сети CRNN с механизмом CTC-декодирования.

Подключение библиотеки осуществляется посредством установки соответствующего пакета из реестра доступных решений PyPI.

В качестве альтернативного решения использовалась библиотека RapidOCR, основанная на моделях семейства PaddleOCR. RapidOCR реализует трехэтапный конвейер:

- 1) обнаружение текстовых областей,
- 2) коррекция ориентации текста,
- 3) распознавание содержимого найденных областей.

Библиотека ориентирована на высокую скорость работы и оптимизирована для запуска на CPU без необходимости использования графического ускорителя. Установка библиотеки также осуществляется посредством установки соответствующего пакета из реестра доступных решений PyPI.

Использование двух различных OCR-систем позволило провести сравнительный анализ качества распознавания и скорости обработки документов.

Результатом работы OCR-модуля является набор текстовых данных, содержащих информацию, извлеченную из документа. Однако полученные данные зачастую имеют неструктурированный характер и могут содержать ошибки распознавания, шумы и избыточные элементы. В связи с этим следующим этапом конвейера становится структуризация информации,

направленная на преобразование OCR-результатов в более удобный для анализа формат.

После структуризации данные передаются в модуль классификации транзакций. Архитектура системы предусматривает возможность использования различных подходов к классификации, включая правило-ориентированный и ML-модели.

Первым исследуемым подходом к классификации стал правило-ориентированный (Rule-Based) метод. Данный подход основывается на наборе заранее определённых экспертных правил, содержащих ключевые слова и шаблоны, характерные для различных категорий расходов. При поступлении транзакции выполняется поиск совпадений между текстовым описанием операции и словарями категорий. Для каждой категории вычисляется вес – некий коэффициент совпадения с заранее зафиксированными правилами. Такой подход обладает высокой интерпретируемостью и не требует обучения модели, однако чувствителен к качеству словаря правил и плохо обобщает новые данные

В качестве ML-подхода была реализована модель логистической регрессии. Перед обучением выполняется подготовка текстовых данных: очистка текста, токенизация и векторизация. В результате каждая транзакция преобразовывается в числовой вектор признаков. После чего выполняется обучение многоклассовой логистической регрессии. Модель вычисляет вероятность принадлежности транзакции к каждому классу по формуле:

$$P(y = k|x) = \sigma(z)_k = \frac{e^{z_k}}{\sum_{j=1}^k e^{z_j}}.$$

Обучение модели осуществляется на синтетическом наборе данных из 5000 транзакций, разделённых на восемь категорий: транспорт, питание, покупки, бытовые расходы, развлечения, здравоохранение, разовые платы, системные операции.

Поскольку открытые размеченные наборы банковских транзакций ограничены и зачастую содержат конфиденциальную информацию, для

проведения экспериментов был сформирован собственный синтетический набор данных. Генерация выполнялась путём создания шаблонов транзакций для каждой категории расходов с последующей случайной вариацией: название организации, сумма, дата операции, описание транзакции. В результате был сформирован набор из 5000 записей, распределённых по восьми классам. Использование синтетических данных позволило обеспечить контролируемое распределение классов и провести корректное сравнение различных методов классификации.

Логистическая регрессия была выбрана благодаря простоте реализации, высокой скорости обучения и хорошей интерпретируемости получаемых коэффициентов.

Подобная организация модуля позволяет исследовать влияние используемого классификатора на итоговое качество обработки документов и проводить сравнительный анализ различных подходов в рамках единого процесса.

Результатом работы системы является определение категории транзакции на основе анализа содержимого документа. При этом благодаря модульной структуре конвейера становится возможным независимое исследование каждого этапа обработки, включая влияние предобработки, OCR и методов классификации на итоговую точность работы системы.

По ходу реализации конвейера также была сформирована блок-схема процесса, которая представлена на рисунке 1:



Рисунок 1 — Блок-схема конвейера

4. Экспериментальное исследование

После реализации прототипа системы было проведено экспериментальное исследование, направленное на анализ эффективности отдельных компонентов конвейера и оценку их влияния на итоговое качество классификации транзакций. Проведение экспериментов является необходимым этапом работы, поскольку позволяет не только проверить работоспособность реализованной архитектуры, но и исследовать взаимосвязи между модулями одной системы.

Первым исследованием стало сравнение используемых OCR-решений. В рамках экспериментов анализировалась эффективность EasyOCR и RapidOCR при обработке одинакового набора документов. Целью исследования является определение различий в качестве распознавания текста и оценки влияния OCR-ошибок на итоговую классификацию транзакций.

Сутью второго эксперимента являлось исследование предобработки на работу OCR-модулей и всей системы в целом. Для этого проводилось сравнение результатов обработки изображений с использованием предварительной обработки и без нее. Подобный подход позволяет оценить эффективность предобработки в контексте повышения устойчивости OCR к визуальным дефектам документов.

В рамках третьего эксперимента внимание уделялось сравнению различных подходов к классификации транзакций. В рамках исследования анализировалась эффективность правило-ориентированных и ML-подходов при обработке одинаковых наборов данных. Сравнение проводилось с учетом особенностей OCR-результатов и качества структуризации информации, что позволяло оценить устойчивость классификаторов к ошибкам распознавания текста.

Проведение экспериментального анализа также было направлено на исследование взаимосвязи между компонентами конвейера. В отличие от изолированного тестирования отдельных модулей, в рамках работы система рассматривалась как единая цепочка обработки данных, в которой изменение

одного компонента оказывает влияние на итоговый результат работы всей архитектуры.

При проведении экспериментов использовался единый набор тестовых данных, включающий изображения документов различного качества и структуры. Подобная организация исследования обеспечивала сопоставимость результатов и позволяла объективно оценивать влияние отдельных компонентов системы на итоговую точность классификации.

4.1. Эксперимент 1 – сравнение OCR

В рамках первого эксперимента проводилось сравнение OCR-решений EasyOCR и RapidOCR при обработке одинакового набора финансовых документов. Целью эксперимента являлась оценка влияния качества OCR-распознавания на итоговую точность классификации транзакций.

Для проведения эксперимента использовался тестовый набор, включающий изображения чеков, квитанций и банковских документов различного качества. В выборку входили документы с шумами, артефактами сжатия, неравномерным освещением, частичной размытостью и вариативностью расположения текстовых блоков. Общий объем тестовой выборки составил порядка 80 изображений документов – по 10 иллюстраций на каждый обозреваемый класс транзакции.

В рамках эксперимента исследовался конвейер обработки, блок-схема которого представлена на рисунке 2:




Рисунок 2 — Блок-схема первого эксперимента

В качестве метрики использовалась итоговая точность корректной классификации транзакций после прохождения полного процесса определения категории.

Сравнение представленных технологий разумно, так как EasyOCR представляет собой OCR-решение на основе PyTorch, использующее комбинацию CNN- и LSTM-архитектур для распознавания текста. RapidOCR, напротив, ориентирован преимущественно на задачи распознавания документов и специализирован на обработке сложных визуальных структур.

По результатам эксперимента RapidOCR продемонстрировал более высокое качество работы. Итоговая точность классификации при использовании RapidOCR составила 68%, тогда как EasyOCR обеспечил 53%. Полученные результаты представлены в таблице 1.

Таблица 1 — Результаты сравнения OCR-модулей

OCR-модуль	Точность классификации
EasyOCR	53%
RapidOCR	68%

В ходе анализа результатов было установлено, что RapidOCR демонстрирует более высокую устойчивость к визуальным дефектам изображений, включая шумы и пониженную контрастность. EasyOCR чаще допускал ошибки при распознавании мелкого текста и сложного расположения текстовых элементов.

Дополнительно было выявлено, что OCR-ошибки обладают накопительным эффектом. Ошибки распознавания текста приводили к ухудшению структуризации данных и снижению эффективности последующего классификатора. Особенно заметно данная проблема проявлялась при использовании правило-ориентированных методов классификации, чувствительных к точному совпадению текстовых шаблонов.

Полученные результаты показали, что качество OCR оказывает существенное влияние на итоговую точность классификации транзакций. Ошибки распознавания, возникающие на раннем этапе процесса, приводили к ухудшению качества структуризации данных и снижению эффективности классификатора. При этом даже незначительные OCR-ошибки могли нарушать

работу правило-ориентированных механизмов, чувствительных к точному совпадению текстовых шаблонов.

4.2. Эксперимент 2 – влияние предобработки

В рамках второго эксперимента исследовалось влияние предобработки на качество работы OCR-ориентированного конвейера. Основной целью эксперимента являлась оценка эффективности предварительной обработки изображений при использовании различных OCR-модулей.

Для проведения исследования использовался тот же набор финансовых документов, что и в предыдущем эксперименте. На этапе предобработки применялись следующие методы обработки изображений:

- преобразование изображения в градации серого,
- повышение контрастности,
- бинаризация,
- базовое подавление шумов.

Выбранные методы обработки изображений являются базовыми операциями цифровой обработки изображений и, так или иначе, применяются повсеместно: от видеонаблюдения и промышленности до медицины и компьютерного зрения.

После предобработки изображения передавались в OCR-модуль, затем выполнялись структуризация данных и классификация транзакций соответственно. Блок-схема, описывающая процесс в рамках второго эксперимента, продемонстрирована на рисунке 3.




Рисунок 3 — Блок-схема второго эксперимента

Эксперимент проводился отдельно для EasyOCR и RapidOCR. Для каждого OCR-решения сравнивались результаты обработки исходных изображений и изображений после предобработки. Результаты показали, что

предобработка оказывает положительное влияние на качество работы всего конвейера. Наиболее заметный прирост наблюдался при использовании EasyOCR, где точность классификации увеличилась с 53% до 61%. RapidOCR также продемонстрировал улучшение качества классификации после применения предобработки – итоговая точность увеличилась с 68% до 73%. Результаты эксперимента представлены в таблице 2.

Таблица 2 — Влияние предобработки на качество классификации

OCR-модуль	Точность без предобработки	Точность с предобработкой
EasyOCR	53%	61%
RapidOCR	68%	73%

В ходе анализа результатов было установлено, что предобработка особенно эффективно при обработке документов с низкой контрастностью, шумами и дефектами сканирования. Использование предварительной обработки позволяло уменьшить количество OCR-ошибок, связанных с размытостью текста и неравномерным освещением.

При этом было выявлено, что предобработка не является панацеей. Было выявлено, что эффективность предварительной обработки зависит не только от особенностей изображения, но и от используемого OCR-решения. Появилась необходимость грамотно выбирать и применять отдельные методы предобработки для определенного OCR-модуля, так как предобработка не является универсальным набором операций и требует адаптации под особенности конкретного OCR-решения для оптимального результата.

Также было отмечено, что в ряде отдельных случаев чрезмерная обработка изображений приводила к ухудшению качества распознавания, изменяя структуру символов и снижая эффективность OCR-модели.

4.3. Эксперимент 3 – сравнение классификации

Третий эксперимент был посвящен сравнению правило-ориентированного и ML-подходов к классификации финансовых транзакций. Целью исследования являлась оценка устойчивости различных методов классификации к OCR-ошибкам и вариативности структуры документов.

Для проведения эксперимента использовался единый набор документов, прошедших одинаковые этапы предобработки, OCR-распознавания и постобработки. Подобная структура эксперимента позволила минимизировать влияние сторонних факторов и сосредоточиться непосредственно на сравнении классификаторов.

Блок-схема конвейера, описывающая исследуемый процесс в рамках третьего эксперимента, представлена на рисунке 4:



Рисунок 4 — Блок-схема третьего эксперимента

Правило-ориентированный классификатор основывается на анализе ключевых слов, текстовых шаблонов и заранее определенных логических правил. Для различных типов транзакций формировались наборы условий, определяющие принадлежность документа к соответствующему классу.

ML-подход реализовывался на основе признакового представления текста. В качестве модели использовалась логистическая регрессия, обученная на размеченной выборке транзакций.

Результаты эксперимента представлены в таблице 3.

Таблица 3 — Сравнение подходов классификации

Метод классификации	Точность классификации
Правило-ориентированный	75%
ML (логистическая регрессия)	66%

В ходе эксперимента было установлено, что правило-ориентированный подход демонстрирует высокую эффективность при обработке типовых документов с предсказуемой структурой и небольшим количеством OCR-ошибок. Использование заранее определенных правил позволяло получать стабильные результаты классификации и обеспечивало высокую интерпретируемость работы системы. Вместе с тем было выявлено, что

эффективность таких методов существенно снижается при увеличении количества OCR-ошибок и появлении нестандартных вариантов представления данных. Даже незначительные изменения текстовых шаблонов, возникающие вследствие ошибок распознавания, могли приводить к нарушению работы логических правил и ухудшению качества классификации.

ML-подход показал более высокую устойчивость к вариативности документов и отдельным OCR-ошибкам. Благодаря способности учитывать совокупность признаков модели машинного обучения обеспечивали более гибкую обработку сложных сценариев, включая случаи с частично поврежденными или неоднозначными данными. Однако эффективность ML-классификатора напрямую зависела от качества обучающего набора данных и количества доступных данных.

Полученные результаты продемонстрировали, что правило-ориентированные методы обеспечивают предсказуемость и простоту интерпретации результатов, тогда как ML-подходы обладают большей гибкостью и лучше адаптируются к сложным сценариям обработки документов. При этом оба направления имеют собственные ограничения, связанные либо с масштабируемостью системы, либо с зависимостью от обучающих данных. Проведенный эксперимент также подтвердил перспективность использования гибридных подходов к классификации транзакций. Комбинирование механизмов позволяет объединить преимущества обоих направлений, используя правила для обработки типовых случаев и ML-модели для анализа сложных или неоднозначных документов.

4.4. Итоговые результаты экспериментов

Проведенное экспериментальное исследование позволило оценить эффективность реализованного конвейера обработки финансовых документов и проанализировать влияние отдельных компонентов системы на итоговое качество классификации транзакций. Полученные результаты подтвердили, что точность работы системы определяется не отдельным модулем, а совокупностью взаимосвязанных этапов обработки данных, начиная с

предобработки изображения и заканчивая принятием решения классификатором.

Одним из ключевых результатов исследования стало подтверждение высокой значимости OCR-модуля в структуре конвейера. Сравнение EasyOCR и RapidOCR показало, что качество распознавания текста оказывает непосредственное влияние на эффективность последующих этапов обработки. В рамках проведенных экспериментов RapidOCR продемонстрировал лучшие результаты по сравнению с EasyOCR, обеспечив более высокую итоговую точность классификации транзакций. Полученные результаты позволяют сделать вывод о том, что при решении задач обработки финансовых документов выбор OCR-модуля оказывает сопоставимое влияние на качество системы с выбором алгоритма классификации.

Анализ промежуточных результатов показал, что OCR-ошибки обладают выраженным накопительным эффектом. Неверно распознанные символы, пропуски отдельных слов или искажение числовых значений приводили к ошибкам на этапе структуризации данных, вследствие чего классификатор получал неполную или искаженную информацию. Особенно чувствительным к подобным ошибкам оказался правило-ориентированный подход, использующий точное совпадение ключевых слов и шаблонов. В ряде случаев ошибка распознавания одного-двух символов приводила к полной потере возможности корректной классификации документа.

Дополнительно было установлено, что предобработка оказывает заметное влияние на качество работы всего конвейера. Использование операций повышения контрастности, бинаризации и подавления шумов позволило улучшить качество распознавания документов низкого качества и обеспечить прирост итоговой точности классификации. При этом результаты показали, что эффективность предобработки существенно зависит от используемого OCR-модуля и характеристик входных данных.

Проведенное исследование также позволило сравнить два принципиально различных подхода к классификации транзакций. Правило-ориентированный

классификатор продемонстрировал наилучшие результаты на подготовленном наборе данных, показав высокую точность при обработке типовых документов с заранее известной структурой. Вместе с тем было установлено, что данный подход обладает ограниченной масштабируемостью и требует ручного расширения базы правил при появлении новых типов документов или изменении форматов данных.

ML-подход показал несколько меньшую точность на текущем этапе исследования, однако продемонстрировал большую устойчивость к вариативности документов и отдельным OCR-ошибкам. Кроме того, машинное обучение обладает лучшей потенциальной масштабируемостью, поскольку качество модели может быть повышено за счет увеличения объема обучающей выборки и использования более сложных алгоритмов классификации. Полученные результаты позволяют предположить, что при дальнейшем расширении набора данных и применении современных методов представления текста ML-подход способен превзойти правило-ориентированные методы по качеству классификации.

Отдельно следует отметить результаты анализа сформированного экспериментального набора данных. В процессе работы был подготовлен набор данных объемом около 5000 транзакций, распределенных по восьми категориям расходов. Использование искусственно сгенерированных данных позволило провести первичную апробацию разработанного конвейера и оценить его работоспособность в контролируемых условиях. Вместе с тем проведенные эксперименты показали необходимость дальнейшего расширения корпуса данных за счет реальных документов, что в свою очередь позволит повысить достоверность результатов и обеспечить более объективную оценку качества системы.

Проведенное исследование также подтвердило перспективность модульной архитектуры конвейера. Возможность независимого исследования модулей позволила проводить сравнительный анализ отдельных компонентов системы и оценивать их влияние на итоговое качество обработки документов.

Подобная организация системы обеспечивает гибкость дальнейшего развития и упрощает интеграцию новых технологий обработки данных.

На основании полученных результатов можно сделать вывод, что наибольшая эффективность достигается при комплексной оптимизации всех компонентов конвейера. Улучшение только одного этапа обработки не обеспечивает максимального прироста качества, поскольку итоговая точность определяется взаимодействием OCR, предобработки, структуризации и классификации. Именно поэтому дальнейшее развитие системы целесообразно осуществлять в направлении комплексной модернизации конвейера, включая исследование более современных OCR-решений, ориентированных на работу со сложными структурами данных, а также разработку гибридных моделей классификации на основе правил и нейросетевых подходов.

5. Перспективы развития

Одним из наиболее перспективных направлений дальнейшей работы является исследование современных моделей из обзора области. В частности, представляет интерес изучение архитектуры Donut, ориентированной на обработку документов без явного использования отдельного OCR-этапа [8]. Подобные модели позволяют выполнять извлечение и интерпретацию информации непосредственно на основе изображения документа, что потенциально может снизить влияние ошибок OCR на качество классификации.

Дополнительно планируется более глубокое исследование методов нейросетевой классификации данных, включая подходы, основанные на использовании RBNN-архитектур [9]. Использование подобных моделей может позволить повысить устойчивость системы к OCR-ошибкам и обеспечить более эффективную обработку сложных и неоднородных документов [10].

Еще одним направлением развития системы является расширение и усложнение экспериментального набора данных. В рамках текущего исследования использовался ограниченный набор документов, достаточный для анализа прототипа системы, однако для дальнейшего повышения качества классификации требуется увеличение объема обучающих данных и расширение разнообразия форматов документов. Дополнительно представляет интерес формирование набора данных, содержащего документы с различными типами искажений, что позволит более полно исследовать устойчивость конвейера к сложным условиям обработки.

ЗАКЛЮЧЕНИЕ

В рамках учебной практики была проведена научно-исследовательская работа, посвященная исследованию и разработке прототипа системы распознавания и классификации финансовых транзакций на основе OCR-ориентированного конвейера.

В процессе исследования был проведен анализ предметной области, была спроектирована и реализован прототип системы, включающая этапы предварительной обработки изображений, OCR-распознавания, структуризации данных и классификации транзакций. Дополнительно был подготовлен экспериментальный набор данных, использованный для проведения сравнительного анализа. Также были проведены эксперименты, результаты которых показали преимущества и недостатки текущей реализации.

За время практики были реализованы компетенции, которые представлены в таблице 4:

Таблица 4 — Реализованные компетенции

Шифр компетенции	Расшифровка приобретаемой компетенции	Расшифровка освоения компетенции
УК-1	Способен осуществлять критический анализ проблемных ситуаций на основе системного подхода, вырабатывать стратегию действий	В ходе практики был проведен анализ существующих подходов к автоматизации обработки документов, выполнено сравнение различных OCR-решений и методов классификации данных. На основе проведенного анализа был сформирован прототип.
УК-4	Способен применять современные коммуникативные технологии, в том числе на иностранном(ых) языке(ах), для академического и профессионального взаимодействия	В процессе выполнения работы осуществлялся анализ англоязычной научной и технической документации по OCR-технологиям и методам классификации данных.
УК-6	Способен определять и реализовывать приоритеты собственной деятельности и способы ее совершенствования на основе самооценки	В рамках практики осуществлялось самостоятельное планирование этапов исследования, распределение задач между анализом предметной области, разработкой системы и проведением экспериментов

Таблица 4 — Реализованные компетенции

Шифр компетенции	Расшифровка приобретаемой компетенции	Расшифровка освоения компетенции
ОПК-1	Способен находить, формулировать и решать актуальные проблемы прикладной математики, фундаментальной информатики и информационных технологий	В ходе практики была исследована задача автоматизации обработки финансовых документов, сформулированы проблемы OCR-распознавания и классификации транзакций
ОПК-2	Способен применять компьютерные/суперкомпьютерные методы, современное программное обеспечение (в том числе отечественного производства) для решения задач профессиональной деятельности	В процессе работы использовались современные программные библиотеки и инструменты обработки данных, включая EasyOCR, RapidOCR и другие.
ОПК-3	Способен проводить анализ математических моделей, создавать инновационные методы решения прикладных задач профессиональной деятельности в области информатики, компьютерного зрения и машинного обучения.	В рамках исследования был проведен сравнительный анализ подходов к классификации транзакций, исследовано влияние предобработки и OCR-решений на итоговое качество системы.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

- 1) Шендо, М. В., Свиридова, Е. В., Липаев, М. В., Володин, А. П. Современное состояние отечественных цифровых экосистем как элемента потребительского рынка онлайн-торговли / М. В. Шендо, Е. В. Свиридова, М. В. Липаев, А. П. Володин. – 2024. – Текст : электронный // Вестник Астраханского государственного технического университета. Серия: Экономика. – № 1. – С. 43-51. – URL: <https://cyberleninka.ru/article/n/sovremennoe-sostoyanie-otechestvennyh-tsifrovyyh-ekosistem-kak-elementa-potrebitelskogo-rynka-onlayn-torgovli> (дата обращения: 18.02.2026).
- 2) Яковлева, Е. А., Виноградов, А. Н., Александрова, Л. В., Филимонов, А. П. Роль технологий искусственного интеллекта в цифровой трансформации экономики / Е.А. Яковлева, А.Н. Виноградов, Л.В. Александрова, А.П. Филимонов. – 2023. – Текст : электронный // Российский центр научной информации. – С. 707-726. – URL: https://journals.rcsi.science/2222-0372/article/view/146769/ru_RU (дата обращения: 18.02.2026).
- 3) Несторов, А. С. Анализ рынка современных информационных систем оптического распознавания символов OCR / А. С. Несторов. – 2020. – Текст : электронный // CyberLeninka. – URL: <https://cyberleninka.ru/article/n/analiz-rynka-sovremennyh-informatsionnyh-sistem-opticheskogo-raspoznavaniya-simvolov-ocr> (дата обращения: 25.02.2026).
- 4) Сенка Дробак, Кристен Линден. Оптическое распознавание символов с помощью нейронных сетей и посткоррекция с использованием методов конечных автоматов / Сенка Дробак, Кристен Линден. – 2020. – Текст : электронный // Международный журнал по анализу и распознаванию документов (IJ DAR) – URL: <https://link.springer.com/article/10.1007/s10032-020-00359-9> (дата обращения: 02.03.2026).
- 5) Джвалин Бхатт, Хуррам Азим Хашми, Мухаммад Зешан Афзал, Дидье Стрикер. Обзор методов обнаружения графических объектов на страницах с помощью глубоких нейронных сетей // Джвалин Бхатт, Хуррам

Азим Хашми, Мухаммад Зешан Афзал, Дидье Стрикер. – 2021. – Текст : электронный // Applied Sciences – URL: <https://www.mdpi.com/2076-3417/11/12/5344> (дата обращения 06.03.2026).

6) Поладов, Ш. Искусственный интеллект и машинное обучение: технологии будущего / Поладов Ш. – 2024. – Текст : электронный // Символ науки. – С. 71-73. – URL: <https://cyberleninka.ru/article/n/iskusstvennyy-intellekt-i-mashinnoe-obuchenie-tehnologii-buduschego> (дата обращения: 20.10.2025).

7) Хинанти, А. П., Фалиана, А., Пути, А. Л., Джема, П. М., Энданг, П. Г. Сравнение точности Tesseract и EasyOCR до и после предварительной обработки изображений / Хинанти, А. П., Фалиана, А., Пути, А. Л., Джема, П. М., Энданг, П. Г. – 2026. – Текст : электронный // Журнал информатики и прикладной электротехники (JITET) – URL: <https://journal.eng.unila.ac.id/index.php/jitet/article/view/8603/3950> (дата обращения: 12.03.2026).

8) Гивук Ким, Тикгю Хон, Мунбин Йим, Чонён Нам, Джинён Пак, Джинён Йим, Вонсок Хван, Санду Юн, Донюн Хан, Сынхён Пак. Трансформатор для понимания документов без оптического распознавания символов / Гивук Ким, Тикгю Хон, Мунбин Йим, Чонён Нам, Джинён Пак, Джинён Йим, Вонсок Хван, Санду Юн, Донюн Хан, Сынхён Пак. – 2021. – Текст : электронный // European Computer Vision Association. – URL: https://www.ecva.net/papers/eccv_2022/papers_ECCV/papers/136880493.pdf (дата обращения: 20.05.2026).

9) Родни М. Гудман, Чарльз М. Хиггинс, Джон В. Миллер. Нейронные сети, основанные на правилах, для классификации и оценки вероятностей / Родни М. Гудман, Чарльз М. Хиггинс, Джон В. Миллер. – 1992. – Текст : электронный // Калифорнийский институт технологий. – URL: <https://authors.library.caltech.edu/records/w6w9f-eaa23> (дата обращения: 22.05.2026).

10) Асмаа М. Аубайд, Алок Мишра, Атул Мишра. Методы машинного обучения и встраивания на основе правил для классификации текстовых

документов / Асмаа М. Аубайд, Алок Мишра, Атул Мишра. – 2024. – Текст : электронный // Международный журнал по анализу и распознаванию документов (IJДАР) – URL: <https://link.springer.com/article/10.1007/s13198-024-02555-w> (дата обращения: 23.05.2026).

ПРИЛОЖЕНИЯ

Приложение 1. Статья

ИССЛЕДОВАНИЕ OCR-ОРИЕНТИРОВАННОГО КОНВЕЙЕРА ДЛЯ КЛАССИФИКАЦИИ ФИНАНСОВЫХ ТРАНЗАКЦИЙ

Миронов Е.П.

Научный руководитель – канд. техн. наук, доцент Николаев К.С.

Казанский (Приволжский) федеральный университет, Институт ВМиИТ

ermironov@kpfu.ru

Автоматизация обработки финансовых документов является одной из актуальных задач, так как связана с ростом объемов неструктурированных данных и необходимостью ускорения обработки транзакционной информации. Значительная часть документов продолжает поступать в виде изображений или сканов, качество которых может существенно различаться в зависимости от условий получения, используемого оборудования и наличия визуальных искажений.

Одним из наиболее распространенных подходов к автоматизации обработки документов являются OCR-ориентированные системы [1], включающие последовательные этапы предобработки изображений, OCR-распознавания, структуризации данных и классификации информации. Основной проблемой подобных систем является накопительный эффект OCR-ошибок, оказывающих влияние на последующие этапы обработки данных.

В общем виде OCR-ориентированный конвейер может быть представлен как последовательность функций:

$$I \xrightarrow{P} F \xrightarrow{OCR} T \xrightarrow{S} X \xrightarrow{C} O,$$

где I — исходное изображение документа, P — модуль предобработки, OCR — модуль распознавания текста с изображения, T — распознанный текст, S — этап структуризации данных, X — вектор признаков, C — классификатор, O — итоговая категория транзакции.

В рамках работы исследуется влияние различных OCR-модулей и методов классификации на итоговую точность определения категории финансовой операции. Общая архитектура исследуемого процесса продемонстрирована на рисунке 1.



Рисунок 1. Блок-схема процесса

Предварительная обработка применяется с целью повышения устойчивости OCR-систем к шумам, артефактам сжатия и дефектам сканирования. На этапе предобработки выполняется базовая обработка изображений:

- перевод в оттенки серого – преобразование цветного RGB-изображения в изображение, в котором все цвета представлены оттенками серого. Данная трансформация помогает отбрасывать шумные пиксели и определять формы на изображении;
- бинаризация – процесс преобразования цветного или полутонового изображения в черно-белое (двухуровневое), где каждый пиксель принимает значение только 0 или 255. Этот метод кардинально уменьшает объем данных и используется для выделения объектов, подготовки к распознаванию текста или контурного анализа;
- подавление шумов – процесс удаления цифровых помех возникающих из-за высокого ISO или плохого освещения;
- повышение контрастности – процесс обработки, при котором увеличивается разница между самыми светлыми и самыми темными участками картинки.

Для OCR-распознавания были исследованы решения EasyOCR и RapidOCR. Выбор данных систем обусловлен различием используемых архитектур и подходов к обработке документов.

EasyOCR представляет собой OCR-библиотеку, основанную на применении глубоких нейронных сетей. Архитектура системы включает два основных этапа: обнаружение текстовых областей на изображении и последующее распознавание текста. Для локализации текстовых блоков используется модель CRAFT – модель анализирует изображение и генерирует две тепловые карты, на основе которых связывает символы этих двух карт в единые текстовые строки, а распознавание выполняется с использованием комбинации сверточных нейронных и рекуррентных сетей. Сверточные слои отвечают за извлечение визуальных признаков символов, тогда как рекуррентные слои позволяют учитывать последовательную структуру текста и зависимости между соседними символами

RapidOCR, напротив, ориентирован преимущественно на задачи обработки документов и построен на базе моделей семейства PaddleOCR. В отличие от EasyOCR, система использует более лёгкие и оптимизированные нейросетевые архитектуры, что позволяет существенно сократить время обработки изображений при сохранении высокого качества распознавания. Дополнительным преимуществом RapidOCR является лучшая адаптация к документам со сложной структурой, низким качеством сканирования и неоднородным расположением текстовых элементов.

Сравнение данных OCR-модулей представляет практический интерес, поскольку они реализуют различные подходы к распознаванию текста. EasyOCR ориентирован на универсальность и поддержку большого количества языков, тогда как RapidOCR делает акцент на производительности и обработке документов. Это позволяет оценить влияние особенностей OCR-архитектуры на итоговую точность классификации финансовых транзакций.

После OCR-распознавания выполнялась структуризация данных, включающая очистку текстовых результатов, нормализацию пробельных последовательностей и выделение признаков документа.

В рамках исследования были рассмотрены два принципиально различных подхода к классификации финансовых транзакций:

- правило-ориентированная классификация;
- классификация на основе методов машинного обучения.

Правило-ориентированный подход основывается на использовании заранее сформированного набора экспертных правил, содержащих ключевые слова, словари и текстовые шаблоны, характерные для различных категорий расходов. После OCR-распознавания и структуризации данных выполняется анализ текстового описания транзакции, в ходе которого осуществляется поиск совпадений с элементами словарей категорий. Для каждой категории рассчитывается оценка соответствия на основе количества найденных совпадений. Итоговая категория определяется по максимальному значению данной оценки.

Поскольку в моем случае используется классификатор на словарях, можно формально записать оценку категории следующим образом $S(c) = \sum_{i=1}^n w_i \cdot I(t_i \in V_c)$, где V_c – словарь ключевых слова категории, w_i – вес признака, I – индикатор наличия слова в документе. Категория же определяется как $\hat{c} = \arg \max_c S(c)$.

Достоинством данного подхода является высокая интерпретируемость результатов и отсутствие необходимости в обучающей выборке. Вместе с тем качество классификации напрямую зависит от полноты и актуальности набора правил, а также чувствительно к ошибкам OCR-распознавания.

Второй подход основан на использовании методов машинного обучения. После этапов OCR-распознавания и структуризации текстовые данные преобразуются в вектор признаков, отражающий содержимое транзакции. В качестве классификатора использовалась многоклассовая логистическая регрессия, обученная на размеченном наборе данных. Вероятность принадлежности транзакции классу k вычисляется с использованием функции Softmax.

$$P(y = k|x) = \sigma(z)_k = \frac{e^{z_k}}{\sum_{j=1}^k e^{z_j}}.$$

Обучение модели выполняется путем минимизации функции кросс-энтропии.

$$L = - \sum_{i=1}^N \sum_{k=1}^K y_{ik} \cdot \log P(y_i = k|x_i).$$

В отличие от правило-ориентированного подхода, модель машинного обучения способна выявлять скрытые зависимости между признаками и учитывать совокупность характеристик документа. Это обеспечивает более высокую устойчивость к вариативности текстов и отдельным ошибкам распознавания, однако требует наличия размеченных данных для обучения и зависит от качества сформированной выборки.

Для проведения экспериментов был подготовлен тестовый набор данных, включающий изображения финансовых документов различного качества. В выборку входили документы с шумами, артефактами сжатия, вариативностью структуры текста и искажениями перспективы.

Первым экспериментом стало сравнение OCR-решений EasyOCR и RapidOCR. Результаты зафиксированы в таблице 1.

Таблица 1 – Результаты первого эксперимента

OCR-модуль	Точность
EasyOCR	53%
RapidOCR	68%

Результаты показывают преимущество RapidOCR над EasyOCR. Рост точности составил 15 процентных, что свидетельствует о большей устойчивости RapidOCR к шумам, неравномерному освещению и сложной структуре документов.

Вторым исследовалось влияние предобработки на работу конвейера. Использование предварительной обработки изображений позволило уменьшить количество OCR-ошибок и повысить устойчивость системы к шумам и дефектам документов.

Таблица 2 – Результаты второго эксперимента

OCR-модуль	Точность без предобработки	Точность с предобработкой
EasyOCR	53%	61%
RapidOCR	68%	73%

Проведенные эксперименты показали, что предобработка оказывает существенное влияние на итоговое качество классификации транзакций. При этом эффективность зависит как от характеристик входных изображений, так и от используемого OCR-решения.

Третий эксперимент – сравнение правило-ориентированного и ML-подходов. Результаты представлены в таблице 3.

Таблица 3 – Результаты третьего эксперимента

OCR-модуль	Точность
Правило-ориентированный	75%
Логистическая регрессия	66%

Несмотря на более высокую точность правило-ориентированного подхода на текущем наборе данных, его масштабируемость ограничена необходимостью ручного расширения базы правил. Логистическая регрессия показала меньшую точность, однако обладает лучшей способностью к обобщению и потенциально может превзойти rule-based подход при увеличении объема обучающих данных.

Результаты исследования подтверждают эффективность сформированной структуры обработки финансовых документов и показывают, что итоговое качество системы определяется совокупностью каждого модуля. В качестве дальнейших направлений исследования рассматриваются интеграция современных моделей, включая Donut [2], исследование RBNN-подходов и расширение экспериментального набора данных.

ЛИТЕРАТУРА

1) Несторов А.С. Анализ рынка современных информационных систем оптического распознавания символов OCR / А.С. Несторов. – URL: <https://cyberleninka.ru/article/n/analiz-rynka-sovremennyh-informatsionnyh-sistem-opticheskogo-raspoznavaniya-simvolov-ocr> (дата обращения: 25.02.2026).

2) Geewook Kim. Donut: Document Understanding Transformer without OCR / Geewook Kim и др. – URL: https://www.ecva.net/papers/eccv_2022/papers_ECCV/papers/136880493.pdf (дата обращения: 20.05.2026).

Приложение 2. Программный код

```
import cv2
from sklearn.model_selection import train_test_split

from src.plugins.classification.custom_rule_based import
RuleClassifier
from src.plugins.classification.ml import MLClassifier
from src.plugins.ocr.easy import EasyOCRWrapper
from src.plugins.ocr.rapid import RapidOCRWrapper
from src.plugins.structurer.temp import SimpleStructurer
from src.plugins.pipeline.pipeline import Pipeline
from src.utils.data_load import load_dataset
from src.utils.image_processor import Preprocessor

def run_experiment():
    # 1. обучаем ML на текстовом датасете
    texts, labels = load_dataset("data/new_dataset.csv")

    X_train, X_test, y_train, y_test = train_test_split(
        texts, labels, test_size=0.3, random_state=42
    )
    ml = MLClassifier()
    ml.train(X_train, y_train)
    structurer = SimpleStructurer()
    preprocessor = Preprocessor()
    # 2. OCR модели
    ocr_models = {
        "Rapid": RapidOCRWrapper(),
        "EasyOCR": EasyOCRWrapper(),
    }
    # 3. тестовые изображения
    test_images = []

    for type_ in ['food', 'transport', 'shopping']:
        for j in range(1,6):

test_images.append((f"data/{type_}_sample/{type_}_{j}.jpg", f"{type_}"))
        print(test_images)
        results = {
            "RAW": {},
            "PREPROCESSING": {}
        }

        for mode in ["RAW", "PREPROCESSING"]:
            print(f"\n\n==== MODE: {mode} =====")
            for ocr_name, ocr in ocr_models.items():
                correct = 0
                print(f"\n=== {ocr_name} ({mode}) ===")
                for path, true_label in test_images:
                    image = cv2.imread(path)
                    if mode == "PREPROCESSING":
                        image = preprocessor.process(image)

                    text = ocr.extract_text(image)
                    doc = structurer.structure(text)
                    pred = ml.classify(doc)
                    print(f"\nImage: {path}")
```

```

        print(f"Predicted: {pred} | True: {true_label}")

        if pred == true_label:
            correct += 1

        acc = correct / len(test_images)
        if ocr_name not in results[mode]:
            results[mode][ocr_name] = acc
        print(f"\n{ocr_name} {mode} accuracy: {acc}")
    return results

def main():
    # 1. Загружаем датасет
    texts, labels = load_dataset("data/new_dataset.csv")
    X_train, X_test, y_train, y_test = train_test_split(
        texts, labels, test_size=0.3, random_state=42
    )
    # 2. Обучаем ML классификатор
    ml_classifier = MLClassifier()
    ml_classifier.train(X_train, y_train)
    structurizer = SimpleStructurer()
    preds = []
    for text in X_test:
        document = structurizer.structure(text) # важно!
        pred = ml_classifier.classify(document)
        preds.append(pred)
    accuracy = sum([1 for p, t in zip(preds, y_test) if p == t]) /
len(y_test)
    print("ML accuracy:", accuracy)
    # 3. Инициализация компонентов
    ocr = EasyOCRWrapper()
    structurizer = SimpleStructurer()
    rule_classifier = RuleClassifier()
    # 4. Создаем pipeline для двух вариантов
    pipeline_rule = Pipeline(ocr, structurizer, rule_classifier)
    pipeline_ml = Pipeline(ocr, structurizer, ml_classifier)
    # 5. Тестовое изображение
    image = cv2.imread("data/food_sample/food_1.jpg")
    # 6. Запуск
    result_rule = pipeline_rule.run(image)
    result_ml = pipeline_ml.run(image)
    print("=== Rule-based ===")
    print(result_rule)
    print("\n=== ML ===")
    print(result_ml)

if __name__ == "__main__":
    main()
    results = run_experiment()
    print("\n=== FINAL RESULTS ===")
    for mode, res in results.items():
        print(f"\n--- {mode} ---")
        for k, v in res.items():
            print(f"{k}: {v}")

```