

Автоматизированная система распознавания и классификации транзакций на основе анализа изображений

Миронов Егор Петрович

09-535



Автоматизация обработки финансовых документов



Рост объема
финансовых
документов



Сложность обработки
изображений



Необходимость
автоматизации
процесса

Постановка задачи

Цель: разработка и исследование системы классификации транзакций по изображениям

Задачи:



Анализ существующих методов



Реализация прототипа



Формирование архитектуры
системы



Проведение экспериментального
анализа

Проблемные аспекты задачи

Низкое качество
изображений

Ошибки OCR

Вариативность
форматов документов

Неструктурированные данные

Общий обзор подходов

Характеристика	End-to-end модели	OCR-based подход
Общая идея	Прямая классификация изображения	Сначала извлечение текста, затем анализ
Архитектура	Обычно глубокие нейросети (CNN)	Комбинация OCR + NLP/правила
Требования к данным	Очень большие размеченные датасеты	Меньше данных для классификации, но нужен хороший OCR
Точность	Высокая при достаточном обучении	Зависит от качества OCR и последующей обработки
Гибкость	Плохо переносится на новые форматы без дообучения	Легче адаптировать через правила/обработку текста
Зависимость от качества изображения	Умеренная (может учиться инвариантности)	Очень высокая — плохое качество ломает OCR



OCR-based pipeline

Независимое
исследование
компонентов

Взаимозаменяемость
отдельных модулей

Возможность
сравнительного анализа
разных модулей

OCR-технологии

1

Шаблонные

Сравнивают изображение символа с заранее
заготовленным эталоном

2

Признаковые

Анализируют характеристики символа: наличие
замкнутых контуров, линий, углов

3

Структурные

Анализируют, из каких элементов состоит символ.
Основной метод в современных системах

4

Нейросетевые

Используют глубокое обучение для распознавания
текста на сложных фонах, уличных фото или в плохом
качестве

Технологии классификации

Rule-based


Основаны на наборе правил и хорошо интерпретируемы, но плохо масштабируются и требуют ручной поддержки

Методы машинного обучения

более гибкие и способны учитывать сложные зависимости, однако требуют качественных и размеченных данных

Гибридные подходы

сочетают правила и машинное обучение: позволяют балансировать между интерпретируемостью и качеством, но становятся сложнее в разработке и поддержке
(правила используются для обработки очевидных случаев, а модель — для сложных или неоднозначных кейсов)



Реализация pipeline-прототипа

Пред- и постобработка данных



ПРАВИТЕЛЬСТВО РОССИЙСКОЙ ФЕДЕРАЦИИ

РАСПОРЯЖЕНИЕ

от 14 апреля 2021 г. № 963-р

МОСКВА

Внести в пункт 2 распоряжения Правительства Российской Федерации от 16 марта 2020 г. № 635-р (Собрание законодательства Российской Федерации, 2020, № 12, ст. 1825; № 14, ст. 2145; № 19, ст. 3025; № 21, ст. 3314; № 23, ст. 3722; № 24, ст. 3842; № 26, ст. 4181; № 31, ст. 5211; № 32, ст. 5331, 5334; № 35, ст. 5604; № 37, ст. 5763; № 38, ст. 5947; № 39, ст. 6137; № 47, ст. 7618; № 48, ст. 7773; № 50, ст. 8271; № 52, ст. 8907; 2021, № 2, ст. 502; № 5, ст. 928; № 7, ст. 1156, 1172; № 8, ст. 1446; № 10, ст. 1664; № 12, ст. 2089; № 14, ст. 2361, 2404) следующие изменения:

в абзаце четырнадцатом слова "их гражданской принадлежности" заменить словами "по указанному перечню";

в абзаце пятнадцатом слова "указанного государства" заменить словами "государств по указанному перечню";

абзац двадцать второй после слов "из Республики Белоруссия" дополнить словами "и иностранных государств, указанных в приложении № 1 к настоящему распоряжению,".

Председатель Правительства
Российской Федерации



М.Мишустин

1. Что такое Тикабу?

Тикабу - это информационно-развлекательное сообщество, весь контент которого создают пользователи. Администрация сайта лишь следит за порядком и соблюдением правил. Все добавленные новости и комментарии имеют свой рейтинг. Новости на главной странице формируются по особому алгоритму, который отображает в топе наиболее актуальные посты на данный момент. Сайт имеет 4 основных раздела: "Тогда", "Здесь", "Сейчас" и "Сообщества". "Тогда" в свою очередь делится на 2 подраздела: "по времени", где отображаются недавно добавленные и набирающие популярность новости и "по актуальности", где отображаются наиболее

Пред- и постобработка данных

Уто наше тикади?\ Тикади - это информационно-развлекательное сообщество, бес контекста которого создают ползобатели. Флуминизм-рация сайта лишь слезим за норвкю и содружением нябив. Все добавленные новости и комментарии именов свой рейтинг. Новости на главной странице формируются по особым алгоритмам, который отображает в тоне наиболее актуальные новости на данный момент. Сайт имеет 4 страниц раздача: "Новости", "Совещения" и "Лошадьства". Топате в свою определение на 2 подразделения: по времени, где отображаемая информация всегда добавлена и надлежащие новости, где отображаемая информация наиболее

г Мио пане Г ий

Е Е се

Пацияе содта, г [29 пятом и РИ 7 рим

#7 ешь ры >

бош зн ы Е ме на рреадрела: и ре Накия @” Герой р. 122.7 АИ ®

ИЯ ш каб ОИ, и,Чио ПЕРИС, ОР РИ ай

Пред- и постобработка данных

ПРАВИТЕЛЬСТВО РОССИЙСКОЙ ФЕДЕРАЦИИ

РАСПОРЯЖЕНИЕ

от 14 апреля 2021 г. № 963-р

МОСКВА

Внести в пункт 2 распоряжения Правительства Российской Федерации от 16 марта 2020 г. № 635-р (Собрание законодательства Российской Федерации, 2020, № 12, ст. 1825; № 14, ст. 2145; № 19, ст. 3025; № 21, ст. 3314; № 23, ст. 3722; № 24, ст. 3842; № 26, ст. 4181; № 31, ст. 5211; № 32, ст. 5331, 5334; № 35, ст. 5604; № 37, ст. 5763; № 38, ст. 5947; № 39, ст. 6137; № 47, ст. 7618; № 48, ст. 7773; № 50, ст. 8271; № 52, ст. 8907; 2021, № 2, ст. 502; № 5, ст. 928; № 7, ст. 1156, 1172; № 8, ст. 1446; № 10, ст. 1664; № 12, ст. 2089; № 14, ст. 2361, 2404) следующие изменения:

в абзаце четырнадцатом слова "их гражданской принадлежности" заменить словами "по указанному перечню";

в абзаце пятнадцатом слова "указанного государства" заменить словами "государств по указанному перечню";

абзац двадцать второй после слов "из Республики Белоруссия" дополнить словами "и иностранных государств, указанных в приложении № 1 к настоящему распоряжению,".

Председатель Правительства Российской Федерации М.Мишустин

4983652

1. Что такое Гикабу?

Гикабу - это информационно-развлекательное сообщество, весь контент которого создают пользователи.

Администрация сайта лишь следит за порядком и соблюдением правил. Все добавленные новости и комментарии имеют свой рейтинг. Новости на главной странице формируются по особому алгоритму, который отображает в топе наиболее актуальные посты на данный момент. Сайт имеет 4 основных раздела: "Горячее", "Лучшее", "Свежее" и "Сообщества". "Горячее" в свою очередь делится на 2 подраздела: "по времени", где отображаются недавно добавленные и набирающие популярность новости и "по актуальности", где отображаются наиболее

OCR-модуль




EasyOCR

OCR на базе глубокого обучения (PyTorch, CNN + LSTM) для преобразования текста с изображения




RapidOCR

Специализированная OCR/VLM, созданная для задач распознавания и анализа документов




Модуль структуризации

Модуль классификации



Rule-based

Анализ данных или автоматизация происходят на основе жестко прописанных правил и алгоритмов



ML

Вместо написания жестких правил, алгоритм обучается на тестовой выборке, выделяя зависимости в данных

Датасет

```
1 text,label
2 Uber BV payment approved | ref 556733 | amount -572.75 EUR,transport
3 Online transaction Aachener Wasser | card ****8304 | EUR -960.46,bills
4 Debit Card Purchase Zalando SE | ****8845 | -719.24 EUR,shopping
5 Online transaction Zalando SE | card ****3741 | EUR -808.74,shopping
6 Online transaction eBay Germany | card ****7848 | EUR -1012.13,shopping
7 POS Aachener Wasser | CARD ****5415 | TXN 831479 | -757.44 EUR,bills
8 POS Subway DE | CARD ****5293 | TXN 146571 | -37.77 EUR,food
9 Debit Card Purchase Rideshare GmbH | ****6659 | -96.3 EUR,transport
10 Debit Card Purchase Lufthansa | ****4228 | -195.34 EUR,transport
11 Apple Store Cologne payment approved | ref 793889 | amount -1016.14 EUR,shopping
12 Debit Card Purchase FlixBus | ****5537 | -675.72 EUR,transport
13 Online transaction Subway DE | card ****8041 | EUR -148.16,food
14 Online transaction Lufthansa | card ****7336 | EUR -1146.38,transport
15 Debit Card Purchase Energieversorgung | ****4134 | -213.48 EUR,bills
16 Debit Card Purchase Apple Store Cologne | ****8686 | -469.49 EUR,shopping
17 POS Apple Store Cologne | CARD ****1887 | TXN 358842 | -239.59 EUR,shopping
18 Debit Card Purchase Amazon EU SARL | ****5689 | -1166.93 EUR,shopping
19 Debit Card Purchase Apple Store Cologne | ****9461 | -1056.4 EUR,shopping
```

```
1 text,label
2 "McDonalds restaurant receipt total 12.50","food"
3 "Starbucks coffee total 5.20","food"
4 "Uber trip fare 15.00","transport"
5 "Taxi ride payment 22.30","transport"
6 "Amazon online order total 45.99","shopping"
7 "Ebay purchase item price 30.00","shopping"
8 "Electricity bill payment total 60.00","utilities"
9 "Water utility bill 25.00","utilities"
10 "Restaurant dinner total 80.00","food"
11 "Bus ticket payment 3.50","transport"
12 "McDonalds restaurant total 12.50","food"
13 "Burger King meal receipt 8.30","food"
14 "KFC order payment 10.20","food"
15 "Starbucks coffee 5.60","food"
16 "Subway sandwich bill 7.40","food"
17 "Pizza Hut order total 15.00","food"
18 "Dominos pizza receipt 13.20","food"
19 "restaurant dinner total 25.00","food"
20 "cafe latte cappuccino 6.10","food"
21 "fast food combo meal 9.90","food"
22 "Uber ride fare 18.00","transport"
23 "Lyft trip payment 14.50","transport"
24 "taxi ride total 22.30","transport"
25 "bus ticket payment 2.50","transport"
26 "train ticket fare 12.00","transport"
27 "metro subway pass 3.00","transport"
28 "flight ticket booking 120.00","transport"
29 "airport shuttle 8.00","transport"
30 "car rental payment 45.00","transport"
31 "fuel station petrol 30.00","transport"
32 "Amazon online order 45.99","shopping"
33 "Ebay purchase item 30.00","shopping"
34 "Walmart store receipt 20.50","shopping"
35 "Ikea furniture bill 80.00","shopping"
36 "AliExpress order payment 12.99","shopping"
37 "Apple store purchase 999.00","shopping"
```


Walmart

Express

NUEVA WAL MART DE MEXICO S DE RL DE CV
NEXTENGO 78 STA. CRUZ ACAYUCAN 02770
AZCAPOTZALCO MEX CDMX RFC. NWM9709244W4

UNIDAD NARVARTE
REIDE TERREROS # 1461 CP. 03020 CDMX
QUEJAS Y SUGERENCIAS 800 007 3273
REGIMEN FISCAL - 601
GENERAL DE LEY PERSONAS MORALES
VENTA EN LINEA 800 367 8737

TDA#3812 OP#00000254 TE# 079 TR# 02410
7506495008192 PARACETAMO
2 X \$10.00 \$ 20.00
TOTAL \$ 20.00
BANCOMER \$ 20.00
CAMBIO \$ 0.00
VEINTE PESOS 00/100 M.N.
TARJETA: MASTERCARD
CUENTA: 5023 I
IMPORTE: 20.00
AUTORIZACION: 579819
AFILIACION: 0234054
AID: A000000004101000
ARQC: 581073B658A3ACA6
ARTICULOS VENDIDOS 2
FU# iz8SXv k0ja5m YL9sGW 1Lkww
TC# 7221441429226468067
TS:280422092404
"Como te atendimos?"
www.miopinionwmx.com
COMPRA EN LINEA EN WALMART.COM.MX
CASHI MAS QUE EFECTIVO LA APP QUE
HECOMPENSA TUS COMPRAS. OBTEN 2% DE
BONIFICACION AL REALIZAR TU PAGO.
DESCARGALA YA!
28/02/22 09:24

Tiffany & Co.

123 Main Street
City, State ZIP
(555) 555-5555
Store: 9431 | Register: 18
Date: 11/24/2025 | Time: 10:10 PM
Transaction: 727306 | Associate: IN82

Vintage Designer Handbag \$450.00
Antique Art Deco Lamp \$325.00

Subtotal \$775.00
Tax \$65.88
Total \$840.88

Payment Mastercard
Card number *** ** 3864
Card Type Mastercard | Entry: Chip
Authorization 826681533418
Status APPROVED

Thank you for shopping at Tiffany & Co.,
Please keep this receipt for warranty
purposes.

countdown

countdown.co.nz

9554 Belfast PH: 03 323 7075
755 Main North Road
Tax Invoice/Credit Note - GST No. 44-833-938

Apple Simply Red Md 1.80
0.515 kg NET @ \$3.50/kg 3.84
Mini Square Cheese& Chive 8pk 3.00
Brioche Sliders 8pk 15.00
Paseo 3 Ply T/tissue 24pk Value 3.50
Free From Lactose Lite Milk 1 L 9.50
Countdown Eggs Barn Size7 12pk 6.30
Countdown Ice Cream Vanilla 2L 6.55
Equal Fresh Lean Meat 500g 11.00
WW Frozen Chicken Nuggets Battered 1Kg 1.99
^ Asparagus Bunch NZ 6.20
^ Westgold Butter Unsalted 400G 3.49
^ Dove Bar Regular 4x90g 1.00
^ Mars Bar 47g 4.60
^ Hrtland Potato Chpssthrn Salt 150g
Qty 2 @ \$2.30 each
15 SUBTOTAL \$77.77
TOTAL \$77.77

TAX INVOICE

Thanks For Your Purchase From NIKE

Invoice Number
G009658NG940
Order Number
DA-1352-300

Ship To
RUTANSH JAGTAP
C 79 Vraj Villa Bungalows Opp
Savita Hospital near Parivar char rasta
Waghodiya road, Vadodara, Gujarat
390025

Invoice & Shipment Date
04-01-2023
GSTIN - 24AAMCS4913M1ZZ

Bill To
RUTANSH JAGTAP
C 79 Vraj Villa Bungalows Opp
Savita Hospital near Parivar char rasta
Waghodiya road, Vadodara, Gujarat
390025

Style	Description	Qty	Rate	Discount	Current Rate	Net Payable	GST & SGST
DA-1352-300	NIKE METCON 7	1	₹8996		₹8996	₹8996	18%

Total Value:	₹7,786
GST:	₹1,210
Invoice Total:	₹8,996
Payment Methord(s):	Debit Card

Apple

Apple Stonestown
3251 20th Avenue
San Francisco, CA 94132
stonestown@apple.com
415-242-7890
www.apple.com/retail/stonestown

October 06, 2021 10:56 AM

Apple Store Pickup Confirmation

Web Order Number: W870170838

AIRPODS MAX SPACE GRAY-AME \$ 549.00
Tax \$ 47.35
Part Number: MGYH3AM/A
Serial Number: H0YGD4MKP3W9
For Support, Visit: www.apple.com/support

the full retail price of your products. Visit online Order Status to view your receipt.

* R 0 3 3 5 7 2 5 8 2 2 *

http://apple.com/l
arn how to set up your produc

Uber

Total: \$43.83
Wed, Nov 08, 2019

Thanks for riding,
Steven

We're glad to have you as an
Uber Rewards Gold Member.

Total \$43.83

You earned 87 points on this trip

Trip Fare \$38.81

Subtotal \$38.81
NY Black Car Fund \$1.03
TNC Assessment Fee \$1.59
Wait Time \$0.00
Tolls, Surcharges, and Fees \$2.40

Amount Charged
Uber Cash \$43.83

Промежуточный итог реализации

- 1 — Реализован прототип системы
- 2 — Обеспечена модульность системы
- 3 — Подготовлен экспериментальный датасет
- 4 — Реализован экспериментальный фундамент


Проведенные эксперименты



Влияние OCR


Влияние пред- и постобработки

Rule-based vs ML




Эксперимент 1 – Влияние OCR

Эксперимент 1 – Результаты



RapidOCR



EasyOCR

Эксперимент 1 – Выводы

1

Вывод 1.1

Модуль OCR не менее важный компонент pipeline в задачах классификации

2


Вывод 1.2

Оптимизация OCR – эффективная точка роста

3


Вывод 1.3

Ошибки при работе имеют накопительный эффект




Эксперимент 2 – Влияние пред- и постобработки


Эксперимент 2 - Результаты




RapidOCR



EasyOCR



RapidOCR + preprocessing



EasyOCR + preprocessing

Эксперимент 2 – Выводы

1

Вывод 2.1

Эффективность preprocessing зависит от конкретного OCR-решения

2


Вывод 2.2

Улучшение обрабатываемых данных достигаются не всегда

3


Вывод 2.3

Наибольший КПД достигается от комбинации компонентов




Эксперимент 3 – Сравнение подходов классификации

Эксперимент 3 – Результаты



Rule-based



ML (регрессия)

Эксперимент 3 – Выводы

1

Вывод 3.1

Rule-based подход обеспечивает предсказуемость

2

Вывод 3.2

ML выигрывает в сложных и неявных сценариях

3

Вывод 3.3

На практике подходы дополняют друг друга

План дальнейшей работы

Расширение
используемых данных

Развитие модуля
структуризации

Общее развитие
ключевых модулей

Развитие экспериментов

Исследование Donut и RBNN

Ожидаемые результаты

1

Устойчивость к ошибкам OCR

2

Повышение точности классификации

3

Исследование влияния компонентов pipeline

4

Выявление закономерностей

5

Формирование оптимального pipeline